

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
федеральное государственное автономное образовательное учреждение
высшего образования «Санкт-Петербургский политехнический
университет Петра Великого»

Институт компьютерных наук и кибербезопасности

Высшая школа технологий искусственного интеллекта

Направление: 02.03.01 «Математика и компьютерные науки»

I часть	a	b	c	d	e	f	g
	+	+	+	+	+	+	✓
II часть	a	b	c	d	e	f	
	+	+	+	+	+	+	

Отчет о выполнении ИДЗ №4
по дисциплине «Математическая статистика»
Вариант 11

Студент,
группы 5130201/30101

_____ Мартыненко А. П.

Преподаватель

_____ Малов С.В.

«_____» _____ 2026г.

1 Часть 1

1.1 Исходные данные

Результаты статистического эксперимента приведены на рисунке 1. Требуется оценить характер зависимости наблюдаемой переменной Y от ковариаты X .

Таблица 1 $\alpha = 0.02; h = 0.69.$

No	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
Y	11.90	12.18	12.37	12.96	12.52	11.11	12.42	13.59	13.67	12.80	12.32	12.62	11.58	13.42	11.89	11.76	12.73
X	4	3	3	3	1	4	2	1	0	2	2	2	5	2	3	3	3
No	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34
Y	12.25	12.96	12.15	13.78	12.71	13.95	12.66	13.08	12.47	12.19	12.18	12.09	11.27	11.99	12.86	12.19	12.87
X	3	3	2	2	2	1	3	2	3	2	4	3	4	5	2	3	3
No	35	36	37	38	39	40	41	42	43	44	45	46	47	48	49	50	
Y	12.52	13.33	12.41	13.09	12.85	12.30	13.60	13.10	11.65	13.47	12.36	12.74	11.88	12.91	11.50	12.50	
X	4	1	4	3	2	3	2	2	2	2	4	2	4	2	4	4	

Рис. 1. Исходные данные

Параметры: $\alpha = 0.02; h = 0.69.$

а)

Задача: построить графически результаты эксперимента. Сформулировать линейную регрессионную модель переменной Y по переменной X . Построить МНК-оценки параметров сдвига β_1 и масштаба β_2 . Построить полученную линию регрессии. Оценить визуально соответствие полученных данных и построенной оценки.

Линейная регрессионная модель имеет вид

$$Y = \beta_1 + \beta_2 X + \varepsilon,$$

где β_1 - параметр сдвига (intercept), β_2 - параметр масштаба (угловой коэффициент), ε - случайная ошибка с $E[\varepsilon] = 0, Var(\varepsilon) = \sigma^2$.

Оценки параметров β_1 и β_2 найдем двумя способами:

1. С помощью метода наименьших квадратов.

Классический подход - для нахождения оценок параметров β_1 и β_2 минимизируем суммы квадратов отклонений:

$$\sum_{i=1}^n (Y_i - \beta_1 - \beta_2 X_i)^2 \rightarrow \min.$$

Решение системы уравнений дает:

$$\hat{\beta}_2 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \quad \hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X},$$

где $\bar{X}$ и $\bar{Y}$ — выборочные средние, n — число наблюдений.

Матричный подход. Матричная форма регрессионной модели:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

где $\mathbf{Y}$ — вектор наблюдений, $\mathbf{X}$ — матрица ковариат, $\boldsymbol{\beta} = (\beta_1, \beta_2)^T$ — вектор параметров, $\boldsymbol{\varepsilon}$ — вектор ошибок. Оценки МНК в матричной форме:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

2. С помощью встроенной в R функции `lm`.

Результаты вычислений представлены в таблице 1.

Метод	$\hat{\beta}_1$ (сдвиг)	$\hat{\beta}_2$ (масштаб)
Матричный	13.67127	-0.4138053
Функция <code>lm()</code>	13.67127	-0.4138053

Таблица 1. Результаты вычислений МНК-оценок β_1, β_2

Оба метода дали одинаковые результаты, что подтверждает корректность вычислений.

На рисунке 2 представлены результаты эксперимента и полученная линия регрессии.




Рис. 2. Результаты эксперимента и полученная линия регрессии

По рисунку видно, что данные сильно рассеяны вокруг линии регрессии. При одном и том же значении X наблюдаемые Y варьируются в диапазоне 1-2 единиц. Следовательно, линейная модель описывает общую тенденцию зависимости Y от X , так как при увеличении X значения Y уменьшаются, что соответствует убывающей линии регрессии.

Тогда линейная регрессионная модель имеет вид

$$\hat{Y} = 13.67127 - 0.4138053X$$

Линейная модель убывает, что соответствует отрицательному параметру масштаба ($\beta_2 = -0.4138053$); модель пересекает ось Y в точке, совпадающей с параметром сдвига ($\beta_1 = 13.67127$).

b)

Задача: сформулировать полиномиальную модель, включающую дополнительный член с X^2 . Построить МНК-оценки параметров $\beta_1, \beta_2, \beta_3$ в данной модели. Изобразить графически полученную регрессионную зависимость. Оценить визуально соответствие полученных данных и построенной оценки.

Требуется расширить линейную модель, добавив квадратичный член:

$$Y = \beta_1 + \beta_2 X + \beta_3 X^2 + \varepsilon.$$

Матричный метод МНК: Для полиномиальной модели матрица имеет вид:

$$\mathbf{X} = \begin{pmatrix} 1 & X_1 & X_1^2 \\ \vdots & \vdots & \vdots \\ 1 & X_n & X_n^2 \end{pmatrix}.$$

Оценки параметров:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}, \quad \text{где } \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}.$$

Результаты вычислений представлены в таблице 2.

Метод	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_3$
Матричный	13.77399	-0.5033658	0.0165203
Функция <code>lm()</code>	13.77399	-0.5033658	0.0165203

Таблица 2. Результаты вычислений МНК-оценок $\beta_1, \beta_2, \beta_3$

Оба метода дали одинаковые результаты, что подтверждает корректность вычислений.

На рисунке 3 представлены результаты эксперимента и полученная линия регрессии.




Рис. 3. Линейная и квадратичная регрессия

Тогда полиномиальная регрессионная модель имеет вид

$$\hat{Y} = 13.77399 - 0.5033658X + 0.0165203X^2$$

Полиномиальная модель имеет выпуклую вниз (U-образную) форму, что подтверждается положительным коэффициентом при X^2 ($\hat{\beta}_3 = 0.0165203$), модель пересекает ось Y в точке, равной параметру $\beta_1 = 13.77399$. Минимум функции достигается при $X = \frac{-\beta_2}{2\beta_3} = 15.23$, однако минимум выходит за пределы наблюдений, то есть в диапазоне наблюдений ($X \in [0, 5]$) модель убывает, и квадратичный вклад незначим. Также коэффициент $\beta_3 = 0.0165203$ мал, поэтому на рассматриваемом диапазоне парабола визуально почти не отличается от прямой.

с)

Задача: на базе ошибок полиномиальной модели построить гистограмму. Проверить значимость отклонения от нормального распределения по χ^2 . Визуально оценить данный факт.

Для полиномиальной модели ошибки вычисляются как:

$$e_i = Y_i - \hat{Y}_i = Y_i - (13.77399 - 0.5033658X_i + 0.0165203X_i^2).$$

В регрессионном анализе предполагается, что остатки $\varepsilon_i = Y_i - \hat{Y}_i$ удовлетворяют гипотезе $H_0: \varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Гипотеза H_1 : остатки $\varepsilon_i = Y_i - \hat{Y}_i$ не имеют нормального распределения.

Для проверки нормальности используется критерий χ^2 Пирсона.

Остатки нужно разбить на k интервалов $B_j = (b_{j-1}, b_j]$, где границы выбираются так, чтобы каждый интервал содержал не менее 5 наблюдений. Первый интервал имеет нижнюю границу $-\infty$, а последний — верхнюю границу $+\infty$. Границы интервалов были взяты так, чтобы в каждом интервале было ровно 10 наблюдений.

Наблюдаемые частоты ν_j — количество остатков в B_j .

Вычислим теоретические вероятности:

$$p_j = \Phi\left(\frac{b_j - \mu}{\sigma}\right) - \Phi\left(\frac{b_{j-1} - \mu}{\sigma}\right)$$

где Φ — функция стандартного нормального распределения.

Найдем ожидаемые частоты для $\mathcal{N}(\mu, \sigma)$: $np_j = n \cdot p_j$

Параметры μ и σ находятся путем минимизации статистики χ^2 :

$$\chi^2 = \sum_{j=1}^k \frac{(\nu_j - np_j)^2}{np_j}.$$

В качестве начальных значений использовались выборочное среднее и выборочное стандартное отклонение остатков. После минимизации с помощью функции `optim` были получены оценки параметров:

$$\hat{\mu} = 0.00244657, \hat{\sigma} = 0.5427211$$

Статистика χ^2 подчиняется распределению хи-квадрат с $k - 1 - m$ степенями свободы, где k — количество интервалов, $m = 2$ — количество оцениваемых параметров (μ, σ) .

i	range	ν_j	p_j	np_j	$\frac{\nu_j - np_j}{\sqrt{np_j}}$	$\frac{(\nu_j - np_j)^2}{np_j}$
1	$(-\infty; -0.463]$	10	0.1953810	9.76905	0.07389	0.0054598
2	$(-0.463; -0.108]$	10	0.2237879	11.18940	-0.35557	0.1264287
3	$(-0.108; 0.116]$	10	0.1636302	8.18151	0.63576	0.4041918
4	$(0.116; 0.466]$	10	0.2208317	11.04159	-0.31346	0.0982562
5	$[0.466; \infty)$	10	0.1963691	9.81845	0.05794	0.0033568
$\chi^2_{\text{набл}}$						0.6376933

Таблица 3. Таблица вычисления статистики критерия Пирсона

Гистограмма остатков для полиномиальной модели представлена на рисунке 4.




Рис. 4. Гистограмма остатков

По гистограмме видно, что распределение остатков близко к симметричному и имеет колоколообразную форму, отсутствуют резкие отклоне-

ния. Наложённая кривая нормального распределения согласуется с эмпирической гистограммой.

Неупорядоченные и упорядоченные остатки представлены на рисунке 5.

```
> res
      1      2      3      4      5      6      7      8      9     10     11     12
-0.12484833 -0.23257203 -0.04257203  0.54742797 -0.76714124 -0.91484833 -0.41333633  0.30285876 -0.10398676 -0.03333633 -0.51333633 -0.21333633
      13     14     15     16     17     18     19     20     21     22     23     24
-0.09016524  0.58666367 -0.52257203 -0.65257203  0.31742797 -0.16257203  0.54742797 -0.68333633  0.94666367 -0.12333633  0.66285876  0.24742797
      25     26     27     28     29     30     31     32     33     34     35     36
 0.24666367  0.05742797 -0.64333633  0.15515167 -0.32257203 -0.75484833  0.31983476  0.02666367 -0.22257203  0.45742797  0.49515167  0.04285876
      37     38     39     40     41     42     43     44     45     46     47     48
 0.38515167  0.67742797  0.01666367 -0.11257203  0.76666367  0.26666367 -1.18333633  0.63666367  0.33515167 -0.09333633 -0.14484833  0.07666367
      49     50
-0.52484833  0.47515167
> sort(res)
      43      6      5      30      20      16      27      49      15      11      7      29
-1.18333633 -0.91484833 -0.76714124 -0.75484833 -0.68333633 -0.65257203 -0.64333633 -0.52484833 -0.52257203 -0.51333633 -0.41333633 -0.32257203
      2      33      12      18      47      1      22      40      9      46      13      3
-0.23257203 -0.22257203 -0.21333633 -0.16257203 -0.14484833 -0.12484833 -0.12333633 -0.11257203 -0.10398676 -0.09333633 -0.09016524 -0.04257203
      10     39     32     36     26     48     28     25     24     42     8      17
-0.03333633  0.01666367  0.02666367  0.04285876  0.05742797  0.07666367  0.15515167  0.24666367  0.24742797  0.26666367  0.30285876  0.31742797
      31     45     37     34     50     35     4      19     14     44     23     38
 0.31983476  0.33515167  0.38515167  0.45742797  0.47515167  0.49515167  0.54742797  0.54742797  0.58666367  0.63666367  0.66285876  0.67742797
      41     21
 0.76666367  0.94666367
```

Рис. 5. Неупорядоченные и упорядоченные остатки полиномиальной модели

Число степеней свободы:

$$df = k - 1 - m = 5 - 1 - 2 = 2.$$

При уровне значимости $\alpha = 0.02$ критическое значение:

$$\chi_{\text{крит}}^2 = F_{\chi^2}^{-1}(1 - \alpha, df) = \chi_{0.98}^2(2) = 7.82405.$$

Граница критической области:

$$\Omega_{\alpha} = \{\chi^2 : \chi^2 > \chi_{0.98}^2(2)\} = \{\chi^2 : \chi^2 > 7.82405\} = (7.82405, +\infty)$$

Правило проверки гипотезы: если $\chi_{\text{набл}}^2 > \chi_{\text{крит}}^2$, то H_0 отвергается.

Так как $0.6376933 < 7.82405$, то гипотеза H_0 не отвергается.

Следовательно, выборка остатков согласуется с нормальным распределением.

Найдём p -значение:

$$p\text{-value} = P(\chi_2^2 > 0.6376933).$$

$$p\text{-value} = 0.72699.$$

Это означает, что гипотеза H_0 не отвергается при всех уровнях значимости $\alpha < 0.72699$.

Так как $p\text{-value} > \alpha = 0.02$, гипотеза H_0 не отвергается.

d)

Задача: в предположении нормальности построить частные и совместные доверительные интервалы для параметров β_2 и β_3 уровня доверия $1 - \alpha$.

Полиномиальная регрессионная модель имеет вид

$$Y = \beta_1 + \beta_2 X + \beta_3 X^2 + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2).$$

Уровень значимости $\alpha = 0.02$.

Степени свободы $df = n - p = 47$ (число наблюдений $n = 50$, число параметров $p = 3$ ($\beta_1, \beta_2, \beta_3$)).

Для каждого коэффициента β_j частный доверительный интервал строится по формуле:

$$\hat{\beta}_j \pm t_{1-\alpha/2, df} \cdot SE(\hat{\beta}_j), \text{ где}$$

- $t_{1-\alpha/2, df}$ - квантиль распределения Стьюдента ($t_{0.99, 47} = 2.408345$)
- $SE(\hat{\beta}_j)$ - стандартная ошибка коэффициента, вычисляющаяся по формуле

$$SE(\hat{\beta}_j) = \hat{\sigma} \sqrt{(\mathbf{X}^T \mathbf{X})_{jj}^{-1}}, \text{ где}$$

- $\hat{\sigma}^2 = \frac{1}{n-p} \sum (Y_i - \hat{Y}_i)^2$ - несмещенная оценка дисперсии случайной ошибки в модели линейной регрессии
- $\mathbf{X}$ - матрица регрессоров
- $(\mathbf{X}^T \mathbf{X})_{jj}^{-1}$ - j-тый диагональный элемент обратной ковариационной матрицы

Полученные значения стандартных ошибок:

Коэффициент	Стандартная ошибка (SE)
$\beta_2(X)$	0.25937614
$\beta_3(X^2)$	0.04631272

Таблица 4. Таблица стандартных ошибок

Частные доверительные интервалы для коэффициентов уровня доверия 0.98:

Параметр	Нижняя граница	Верхняя граница
$\beta_2(X)$	-1.12803305	0.1213014
$\beta_3(X^2)$	-0.09501672	0.1280573

Таблица 5. Таблица частных доверительных интервалов

Так как ДИ для $\beta_2 : [-1.128; 0.121]$ содержит 0, следовательно, нельзя отвергнуть гипотезу $H_0 : \beta_2 = 0$ и коэффициент β_2 незначим на уровне α .

Так как ДИ для $\beta_3 : [-0.095; 0.128]$ содержит 0, следовательно, нельзя отвергнуть гипотезу $H_0 : \beta_3 = 0$ и коэффициент β_3 незначим на уровне α .

Совместный доверительный интервал для пары (β_2, β_3) задается неравенством:

$$(\hat{\beta} - \beta)^T \hat{\Sigma}^{-1} (\hat{\beta} - \beta) \leq q \cdot F_{1-\alpha, q, df}, \text{ где}$$

- q - количество параметров ($q = 2$)
- $\hat{\Sigma} = \hat{\sigma}^2(\mathbf{X}^T \mathbf{X})^{-1}$ - ковариационная матрица оценок коэффициентов, которая имеет вид:

$$\Sigma = \begin{pmatrix} Var(\hat{\beta}_2) & Cov(\hat{\beta}_2, \hat{\beta}_3) \\ Cov(\hat{\beta}_2, \hat{\beta}_3) & Var(\hat{\beta}_3) \end{pmatrix},$$

– $Cov(\hat{\beta}_2, \hat{\beta}_3)$ - ковариация между оценками

– $Var(\hat{\beta}_j)$ - дисперсии оценок коэффициента $\hat{\beta}_j$

- $F_{1-\alpha, q, df}$ - квантиль распределения Фишера-Снедекора

Результаты расчетов:

$$\text{Вектор оценок коэффициентов: } \hat{\beta} = \begin{pmatrix} -0.5033658 \\ 0.0165203 \end{pmatrix},$$

$$\text{Ковариационная матрица: } \hat{\Sigma} = \begin{pmatrix} 0.06727598 & -0.01162784 \\ -0.01162784 & 0.00214487 \end{pmatrix},$$

$$\text{Обратная ковариационная матрица: } \hat{\Sigma}^{-1} = \begin{pmatrix} 235.9237 & 1278.999 \\ 1278.999 & 7399.986 \end{pmatrix}.$$

Критическое значение F-распределения $F_{0.98, 2, 47} = 4.256484$.

Совместный доверительный эллипс, показывающий область возможных значений (β_2, β_3) , представлен на рисунке 6.

Так как точка $(0, 0)$ находится вне эллипса, то совместная гипотеза $H_0 : \beta_2 = 0$ и $\beta_3 = 0$ отвергается, следовательно, нельзя исключить оба члена из модели одновременно.




Рис. 6. Совместный доверительный эллипс

Метод Бонферрони строит доверительные интервалы для каждого параметра индивидуально с коррекцией уровня значимости для учёта множественных сравнений. Для двух параметров (β_2 и β_3) уровень значимости корректируется как:

$$\alpha_{\text{Bonf}} = \frac{\alpha}{q}, \quad q = 2 \text{ (количество параметров)}.$$

Учитывается, что мы строим двусторонний доверительный интервал, поэтому делим уровень значимости ещё на 2.

Доверительные интервалы для каждого параметра вычисляются по формуле:

$$\hat{\beta}_j \pm t_{1-\alpha_{\text{Bonf}}/2, df} \cdot SE(\hat{\beta}_j),$$

где:

- $t_{1-\alpha_{\text{Bonf}}/2, df}$ — квантиль распределения Стьюдента с df степенями свободы,
- $SE(\hat{\beta}_j)$ — стандартная ошибка коэффициента.

Совместный доверительный интервал методом Бонферрони представляется как прямоугольник в пространстве (β_2, β_3) , образованный пересечением индивидуальных интервалов:

$$[\text{Нижняя граница для } \beta_2, \text{Верхняя граница для } \beta_2] \times$$

[Нижняя граница для β_3 , Верхняя граница для β_3].

Параметр	Нижняя граница	Верхняя граница
$\beta_2(X)$	-1.1996755	0.1929438
$\beta_3(X^2)$	-0.1078088	0.1408494

Таблица 6. Совместный доверительный интервал методом Бонферрони для коэффициентов уровня доверия 0.98




Рис. 7. Сравнение совместного доверительного эллипса и прямоугольника

Метод Шеффе строит совместную доверительную область для всех линейных комбинаций $a^T \beta = a_1 \beta_2 + a_2 \beta_3$ одновременно. Эта область совпадает с доверительным эллипсом:

$$\{(\beta_2, \beta_3): (\hat{\beta} - \beta)^T \hat{\Sigma}^{-1} (\hat{\beta} - \beta) \leq q \cdot F_{1-\alpha, q, df}\}.$$

Таким образом, эллипс и область Шеффе совпадают. Различие между методами - эллипс используется для одновременного покрытия самой

точки (β_2, β_3) , тогда как метод Шеффе гарантирует, что для любого вектора a интервал $a^T \hat{\beta} \pm S_\alpha \cdot SE(a^T \hat{\beta})$ накрывает истинное значение $a^T \beta$ с вероятностью не менее $1 - \alpha$.

Правки: не нужна линейная комбинация, просто для каждого β_i Шеффе построить

Как пример рассмотрим линейную комбинацию $v = \beta_3$ (то есть вектор $a = (0, 1)^T$), для которой доверительный интервал вычисляется по формуле:

$$\hat{v} \pm x_\alpha \cdot SE(\hat{v}),$$

где:

- $\hat{v} = \hat{\beta}_3$ — оценка линейной комбинации,
- $SE(\hat{v}) = \sqrt{a^T \Sigma a}$ — стандартная ошибка комбинации,
- $a = (1, 1)^T$ — вектор коэффициентов линейной комбинации,
- $x_\alpha = \sqrt{q \cdot F_{1-\alpha, q, df}}$ — поправка Шеффе,
- $F_{1-\alpha, q, df}$ — это квантиль распределения Фишера–Снедекора,
- $q = 2$ — количество параметров.

Оценка	Нижняя граница	Верхняя граница
β_2	-1.260147	0.253416
β_3	-0.1186063	0.151647

Таблица 7. Совместный доверительный интервал методом Шеффе для линейной комбинации уровня доверия 0.98

е)

Задача: сформулировать гипотезы линейности зависимости и независимости наблюдаемой переменной Y от ковариаты X . Провести проверку значимости.

Исходная полиномиальная модель имеет вид

$$E(Y|z) = \beta_1 + \beta_2 z + \beta_3 z^2 + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2).$$

Постановка гипотез:

1. Гипотеза о линейности:

$H_0: \beta_3 = 0$ ($E(Y|z) = \beta_1 + \beta_2 z$, модель линейна);

$H_1: \beta_3 \neq 0$ (модель квадратична).

2. Гипотеза о независимости:

$H_0: \beta_2 = \beta_3 = 0$ ($E(Y|z) = \beta_1$, Y не зависит от X);

$H_1: \beta_2 \neq 0$ и/или $\beta_3 \neq 0$ (существует зависимость).

Используем F-тест для сравнения моделей. Статистика теста:

$$F = \frac{(SSE_{\text{restricted}} - SSE_{\text{full}})/q}{SSE_{\text{full}}/(n - p)}, \text{ где}$$

- SSE - сумма квадратов ошибок ($SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$)
 - restricted - модель при выполнении H_0
 - full - полная модель без ограничений
- q - разница в числе параметров b_j ($q = p_{\text{full}} - p_{\text{restricted}}$)
- n - число наблюдений
- p - число параметров b_j в полной модели

1. Тест на линейность (сравнение линейной и квадратичной моделей):

Сравнение	SSE	df	F	p-value
$Y \sim X$	11.286	48	—	—
$Y \sim X + X^2$	11.256	47	0.1272	0.7229

Таблица 8. Проверка гипотезы линейности

Вывод: $p = 0.7229 > \alpha = 0.02 \Rightarrow$ Не отвергаем $H_0: \beta_3 = 0$. Зависимость линейна, квадратичный член незначим.

2. Тест на независимость (сравнение константной и квадратичной моделей):

Сравнение	SSE	df	F	p-value
$Y \sim 1$	20.961	49	—	—
$Y \sim X + X^2$	11.256	47	20.263	$4.509471 \cdot 10^{-7}$

Таблица 9. Проверка гипотезы независимости

Вывод: $p = 4.509471 \cdot 10^{-7} \ll \alpha = 0.02 \Rightarrow$ Отвергаем $H_0: \beta_2 = \beta_3 = 0$. Зависимость Y от X значима.

f)

Задача: с использованием AIC и BIC выбрать наилучшую модель.

AIC (Информационный критерий Акаике) основан на минимизации информационной энтропии:

$$\text{AIC} = 2k - 2 \ln(\hat{L}),$$

где k — число параметров, $\hat{L}$ — максимизированное значение функции правдоподобия.

Чем меньше $\ln(L)$, тем лучше модель объясняет данные. В то же время штраф $2k$ увеличивается с ростом количества параметров k .

Для нормальной регрессии:

$$-2 \ln(\hat{L}) = n \ln(2\pi) + n \ln \left(\frac{\text{SSE}}{n} \right) + n$$

BIC (Байесовский информационный критерий) аппроксимирует логарифм апостериорной вероятности:

$$\text{BIC} = k \ln(n) - 2 \ln(L).$$

У BIC более строгий штраф за большое количество параметров: $k \ln(n)$

Чем меньше значения AIC/BIC, тем лучше модель. Различия > 2 считаются значимыми.

Модель	AIC	BIC
$Y \sim 1$	102.42588	106.24993
$Y \sim X$	73.47188	79.20795
$Y \sim X + X^2$	75.33670	82.98479

Таблица 10. Сравнение моделей по информационным критериям

Линейная модель ($Y \sim X$) имеет наименьшие AIC и BIC, следовательно, она является наилучшей. Это согласуется с результатом F-теста, в котором гипотеза $H_0 : \beta_3 = 0$ не была отвергнута.

Константная модель имеет большие значения AIC и BIC, так как есть зависимость переменной Y от ковариаты X (согласуется с отвержением гипотезы на независимость).

Добавление квадратичного члена X^2 не сильно улучшает модель, так как уменьшение суммы квадратов ошибок оказывается слишком малым, чтобы компенсировать усложнение модели.

Таким образом, зависимость среднего значения отклика от сопутствующей переменной можно считать линейной:

$$E(Y|X) = \beta_1 + \beta_2 X$$

Соответствующая регрессионная модель имеет вид:

$$Y = \beta_1 + \beta_2 X + \varepsilon,$$

где $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ — случайная ошибка модели.

g)

В ходе анализа зависимости наблюдаемой переменной Y от ковариаты X по выборке объёма $n = 50$ были получены следующие результаты.

Линейная модель. МНК-оценки параметров линейной модели $Y = \beta_1 + \beta_2 X + \varepsilon$:

$$\hat{\beta}_1 = 13.671, \quad \hat{\beta}_2 = -0.414.$$

Отрицательный знак $\hat{\beta}_2$ указывает на убывающую зависимость: при увеличении X на единицу среднее значение Y уменьшается примерно на 0,41. Визуально данные заметно рассеяны вокруг прямой, что свидетельствует о существенной случайной составляющей.

Полиномиальная модель. Расширенная модель $Y = \beta_1 + \beta_2 X + \beta_3 X^2 + \varepsilon$ дала оценки:

$$\hat{\beta}_1 = 13.774, \quad \hat{\beta}_2 = -0.503, \quad \hat{\beta}_3 = 0.017.$$

Коэффициент $\hat{\beta}_3$ мал, а минимум параболы достигается при $X^* = 15.23$, то есть далеко за пределами области наблюдений $X \in [0, 5]$. На этом диапазоне квадратичная кривая визуально неотличима от прямой.

Проверка нормальности остатков. Гистограмма остатков полиномиальной модели имеет симметричную колоколообразную форму, согласующуюся с нормальным распределением. Критерий Пирсона χ^2 при $df = 2$ и $\alpha = 0.02$:

$$\chi_{\text{набл}}^2 = 0.638 < \chi_{\text{крит}}^2 = 7.824, \quad p\text{-value} = 0.727.$$

Гипотеза $H_0: \varepsilon \sim \mathcal{N}(0, \sigma^2)$ не отвергается.

Доверительные интервалы для β_2 и β_3 (уровень доверия $1 - \alpha = 0.98$). Частные ДИ (квантиль Стьюдента $t_{0.99; 47} = 2.408$):

$$\beta_2 \in [-1.128; 0.121], \quad \beta_3 \in [-0.095; 0.128].$$

Оба интервала содержат нуль, то есть по отдельности β_2 и β_3 незначимы на уровне $\alpha = 0.02$. Однако совместный доверительный эллипс для пары (β_2, β_3) не содержит точку $(0, 0)$: совместная гипотеза $H_0: \beta_2 = \beta_3 = 0$ отвергается.

Проверка гипотез о структуре зависимости.

- Гипотеза о линейности ($H_0: \beta_3 = 0$): $F = 0.127$, $p = 0.723 > 0.02 \implies$ не отвергается. Квадратичный член незначим.
- Гипотеза о независимости ($H_0: \beta_2 = \beta_3 = 0$): $F = 20.26$, $p = 4.5 \times 10^{-7} \ll 0.02 \implies$ отвергается. Зависимость Y от X значима.

Модель	AIC	BIC
$Y \sim 1$	102.43	106.25
$Y \sim X$	73.47	79.21
$Y \sim X + X^2$	75,34	82,98

Выбор модели по AIC и BIC. Линейная модель имеет наименьшие AIC и BIC. Разница $\Delta AIC = 75.34 - 73.47 = 1.87 < 2$ формально невелика, однако BIC также указывает на линейную модель, а F-тест не выявил значимости β_3 . Совокупность критериев однозначно указывает на линейную модель как наилучшую.

Зависимость среднего значения отклика от ковариаты является линейной и значимой:

$$\hat{Y} = 13.671 - 0.414 X, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2).$$

Добавление квадратичного члена не улучшает описание данных ни статистически, ни по информационным критериям.

2 Часть 2

2.1 Исходные данные

Результаты статистического эксперимента приведены на рисунке 8. Требуется оценить характер зависимости наблюдаемой переменной Y от уровней факторов A и B .

Таблица 2 $\alpha_1 = 0.05; h = 1.70.$

No	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
Y	61.60	62.53	62.33	58.60	58.85	61.72	26.02	28.73	31.66	30.14	31.18	29.83	37.85	39.79	35.99	41.22	35.60
A	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
B	1	1	1	1	1	1	2	2	2	2	2	2	3	3	3	3	3
No	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34
Y	35.08	68.71	69.99	68.13	70.77	67.83	68.89	33.62	29.98	30.44	29.33	30.13	29.88	34.79	33.14	33.39	33.44
A	1	1	1	1	1	1	1	2	2	2	2	2	2	2	2	2	2
B	3	4	4	4	4	4	4	1	1	1	1	1	1	2	2	2	2
No	35	36	37	38	39	40	41	42	43	44	45	46	47	48			
Y	33.02	34.95	76.78	78.65	76.25	76.27	73.33	73.30	43.02	39.74	44.16	43.05	48.55	41.72			
A	2	2	2	2	2	2	2	2	2	2	2	2	2	2			
B	2	2	3	3	3	3	3	3	4	4	4	4	4	4			

Рис. 8. Исходные данные

Параметры: $\alpha_1 = 0.05; h = 1.70.$

а)

Задача: сформулировать модель двухфакторного дисперсионного анализа. Построить МНК-оценки параметров и несмещённую оценку дисперсии.

Модель для двухфакторного дисперсионного анализа с взаимодействием записывается в виде:

$$E(Y \mid A = a_i, B = b_j) = \mu_{ij} = \mu + \alpha_i^{(1)} + \alpha_j^{(2)} + \alpha_{ij}^{(12)},$$

где:

- μ — общее среднее значение переменной Y ;
- $\alpha_i^{(1)}$ — главный эффект i -го уровня фактора A ;
- $\alpha_j^{(2)}$ — главный эффект j -го уровня фактора B ;
- $\alpha_{ij}^{(12)}$ — эффект взаимодействия между i -м уровнем фактора A и j -м уровнем фактора B .

В эксперименте фактор A имеет два уровня ($i = 1, 2$); фактор B имеет 4 уровня ($j = 1, 2, 3, 4$).

Ограничения, необходимые для однозначности оценок параметров:

- $\alpha_1^{(1)} = 0, \alpha_1^{(2)} = 0$ (первый уровень каждого фактора является базовым);
- $\alpha_{1j}^{(12)} = 0, \alpha_{i1}^{(12)} = 0$ для $i = \{1, 2\}, j = \{1, 2, 3, 4\}$ (эффекты взаимодействия с базовыми уровнями равны нулю);
- $\mu = \mu_{11}$ (общее среднее равно значению при базовых уровнях факторов).

Таким образом, модель содержит 8 свободных параметров:

- μ - общее среднее значение переменной Y
- $\alpha_2^{(1)}$ - главный эффект A
- $\alpha_2^{(2)}, \alpha_3^{(2)}, \alpha_4^{(2)}$ - главные эффекты B
- $\alpha_{22}^{(12)}, \alpha_{23}^{(12)}, \alpha_{24}^{(12)}$ - эффекты взаимодействия.

Построение МНК-оценок параметров

Цель метода наименьших квадратов (МНК) — найти такие значения параметров $(\mu, \alpha_i^{(1)}, \alpha_j^{(2)}, \alpha_{ij}^{(12)})$, которые минимизируют сумму квадратов остатков (SSE):

$$SSE = \sum_{i=1}^{d_1} \sum_{j=1}^{d_2} \sum_{k=1}^{n_{ij}} \left(Y_{ijk} - (\mu + \alpha_i^{(1)} + \alpha_j^{(2)} + \alpha_{ij}^{(12)}) \right)^2.$$

МНК-оценки параметров вычисляются по формуле

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y},$$

где:

- $\mathbf{X}$ — матрица плана, кодирующая структуру модели (включая столбцы для общего среднего, главных эффектов и взаимодействий);
- $\mathbf{Y}$ — вектор наблюдений;
- $\hat{\beta}$ — вектор оценок параметров.

Матрица плана $\mathbf{X}$ строится следующим образом:

- Первый столбец состоит из единиц (для общего среднего μ);
- Для главных эффектов факторов A и B используются фиктивные переменные: уровни A_2, A_3, B_2, B_3 кодируются как 1, если соответствующий уровень присутствует, и 0 в противном случае;

- Для эффектов взаимодействия $A \times B$ создаются дополнительные столбцы, которые равны 1, если одновременно выполняются соответствующие уровни факторов, и 0 в противном случае.

Пример матрицы наблюдений для $A_1, A_2, B_1, B_2, B_3, B_4$:

$$\mathbf{X} = \begin{pmatrix} 1 & A_2 & B_2 & B_3 & B_4 & A_2B_2 & A_2B_3 & A_2B_4 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 & 1 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \end{pmatrix}$$

Дисперсия ошибок ($\hat{\sigma}^2$) оценивается как:

$$\hat{\sigma}^2 = \frac{SSE}{n - r},$$

где:

- SSE — сумма квадратов остатков;
- $n = d_1 \cdot d_2 \cdot n_{ij} = 2 \cdot 4 \cdot 6 = 48$ — общее количество наблюдений;
- $r = 8$ — количество свободных параметров в модели.

Чем меньше $\hat{\sigma}^2$, тем лучше модель описывает данные.

Число степеней свободы: $df = n - r = 48 - 8 = 40$

Параметр	Значение
μ	60.9383
$\alpha_2^{(1)}$	-30.3750
$\alpha_2^{(2)}$	-31.3450
$\alpha_3^{(2)}$	-23.3500
$\alpha_4^{(2)}$	8.1150
$\alpha_{22}^{(12)}$	34.57
$\alpha_{23}^{(12)}$	68.55
$\alpha_{24}^{(12)}$	4.695

Таблица 11. Оценки параметров двухфакторной модели ANOVA

Вычисленные значения:

$$SSE = 154.1759, \quad \hat{\sigma}^2 = 3.854398.$$

- Общее среднее значение (μ) равно 60.9383.
- Главные эффекты показывают, как уровни факторов A и B влияют на результат относительно базовых уровней.
- Эффекты взаимодействия показывают, как комбинации уровней факторов A и B дополнительно влияют на результат.
- Оценка дисперсии ошибок ($\hat{\sigma}^2$) равна 3.854398, следовательно модель достаточно хорошо описывает экспериментальные данные.

b)

Задача: проверить визуально согласование исходных данных с предположением аддитивности влияния факторов. Построить графически оценку зависимости уровней фактора A при каждом фиксированном значении фактора B . Наблюдается ли эффект пересечения факторов?

Для проверки согласования исходных данных с предположением аддитивности влияния факторов необходимо построить график зависимости значений Y от уровня фактора A для каждого фиксированного значения фактора B . Результаты представлены на рис. 9.




Рис. 9. Оценка зависимости уровней фактора A при каждом фиксированном значении фактора B

Каждая линия соответствует своему уровню фактора B . Если бы влияние факторов было бы аддитивным, линии были бы параллельны. Так как они не параллельны и некоторые из них пересекаются, между факторами A и B существует взаимодействие. Следовательно, данные не согласуются с предположением аддитивности влияния факторов.

По графику видно, что:

- для B_1, B_4 Y уменьшается по мере увеличения уровня A ,
- для B_2, B_3 Y увеличивается по мере увеличения уровня A .

Значит, влияние фактора A зависит от уровня фактора B .

Для построения графика взаимодействия факторов используются средние значения отклика для каждой комбинации уровней факторов A и B . В модели с взаимодействием оценка среднего вычисляется по формуле:

$$\hat{Y}_{ij} = \hat{\mu} + \hat{\alpha}_i^{(1)} + \hat{\alpha}_j^{(2)} + \hat{\alpha}_{ij}^{(12)}.$$

В качестве базовых уровней выбраны A_1 и B_1 , поэтому $\hat{Y}_{11} = \hat{\mu}$. Подставим найденные оценки параметров модели.

- Комбинация A_1, B_1 : $\hat{Y}_{11} = 60.9383$.
- Комбинация A_2, B_1 :

$$\hat{Y}_{21} = \hat{\mu} + \hat{\alpha}_2^{(1)} = 60.9383 - 30.3750 = 30.5633.$$

- Комбинация A_1, B_2 :

$$\hat{Y}_{12} = \hat{\mu} + \hat{\alpha}_2^{(2)} = 60.9383 - 31.3450 = 29.5933.$$

- Комбинация A_2, B_2 :

$$\hat{Y}_{22} = \hat{\mu} + \hat{\alpha}_2^{(1)} + \hat{\alpha}_2^{(2)} + \hat{\alpha}_{22}^{(12)}.$$

$$\hat{Y}_{22} = 60.9383 - 30.3750 - 31.3450 + 34.5700 = 33.7883.$$

- Комбинация A_1, B_3 :

$$\hat{Y}_{13} = \hat{\mu} + \hat{\alpha}_3^{(2)} = 60.9383 - 23.3500 = 37.5883.$$

- Комбинация A_2, B_3 :

$$\hat{Y}_{23} = \hat{\mu} + \hat{\alpha}_2^{(1)} + \hat{\alpha}_3^{(2)} + \hat{\alpha}_{23}^{(12)}.$$

$$\hat{Y}_{23} = 60.9383 - 30.3750 - 23.3500 + 68.5500 = 75.7633.$$

- Комбинация A_1, B_4 :

$$\hat{Y}_{14} = \hat{\mu} + \hat{\alpha}_4^{(2)} = 60.9383 + 8.1150 = 69.0533.$$

- Комбинация A_2, B_4 :

$$\hat{Y}_{24} = \hat{\mu} + \hat{\alpha}_2^{(1)} + \hat{\alpha}_4^{(2)} + \hat{\alpha}_{24}^{(12)}.$$

$$\hat{Y}_{24} = 60.9383 - 30.3750 + 8.1150 + 4.6950 = 43.3733.$$

Полученные значения являются точками, через которые проходят линии на графике взаимодействия факторов.

На графике видно, что линии для разных уровней B пересекаются:

- зеленая линия для B_2 пересекает красную линию для B_1 ближе к уровню A_2 ;
- синяя линия для B_3 пересекает красную линию для B_1 и фиолетовую линию для B_4 между уровнями A_1 и A_2 .

Это явно указывает на наличие эффекта взаимодействия между факторами A и B .

с)

Задача: провести анализ ошибок. По гистограмме ошибок оценить визуально согласование с гипотезой нормальности.

Ошибки (остатки) модели вычисляются как разность между наблюдаемыми значениями (Y_{ijk}) и предсказанными значениями ($\hat{Y}_{ijk}$):

$$e_{ijk} = Y_{ijk} - \hat{Y}_{ijk}.$$

Для вычисления ошибок используется модель, построенная в R:
`residuals_full <- residuals(model_full)`

Гистограмма ошибок используется для визуальной оценки распределения ошибок. Нужно выбрать границы интервалов так, чтобы в каждом интервале было не менее 5 остатков.

i	Диапазон	ν_i
1	$(-\infty; -1.452]$	10
2	$(-1.452; -0.405]$	9
3	$(-0.405; 0.491]$	10
4	$(0.491; 1.299]$	9
5	$(1.299; +\infty)$	10

Таблица 12. Диапазоны и количество наблюдений

На рисунке 10 показана гистограмма ошибок вместе с кривой нормального распределения.




Рис. 10. Гистограмма ошибок

По результатам анализа графика можно сказать, что гистограмма ошибок имеет форму, близкую к колоколообразной, что указывает на возможное соответствие нормальному распределению. Таким образом, ошибки модели согласуются с предположением о нормальности.

d)

Задача: провести дисперсионный анализ, начиная с проверки значимости взаимодействий факторов на результаты эксперимента.

Проверим выполнение следующих гипотез:

- Гипотеза $H_{(12)}$: отсутствие взаимодействия факторов A и B

$$\alpha_{ij}^{(12)} = 0, \quad \text{где } i = 1, \dots, d_1, j = 1, \dots, d_2.$$

Модель: $E(Y \mid z_1 z_2) = \mu + \alpha_{z_1}^{(1)} + \alpha_{z_2}^{(2)}$ — аддитивная модель.

- Гипотеза $H_{(1)}$: отсутствие влияния фактора A

$$\alpha_i^{(1)} = 0, \alpha_{ij}^{(12)} = 0, \quad \text{где } i = 1, \dots, d_1, j = 1, \dots, d_2.$$

$$\text{Модель: } E(Y \mid z_1 z_2) = \mu + \alpha_{z_2}^{(2)}.$$

- Гипотеза $H_{(2)}$: отсутствие влияния фактора B

$$\alpha_j^{(2)} = 0, \alpha_{ij}^{(12)} = 0, \quad \text{где } i = 1, \dots, d_1, j = 1, \dots, d_2.$$

$$\text{Модель: } E(Y \mid z_1 z_2) = \mu + \alpha_{z_1}^{(1)}.$$

- Гипотеза $H^{(0)}$: отсутствие влияния факторов

$$\alpha_i^{(1)} = 0, \alpha_j^{(2)} = 0, \alpha_{ij}^{(12)} = 0, \quad \text{где } i = 1, \dots, d_1, j = 1, \dots, d_2.$$

$$\text{Модель: } E(Y \mid z_1, z_2) = \mu.$$

Для проверки гипотез нужно построить следующие модели:

1. Полная модель:

$$Y = \mu + \alpha_{z_1}^{(1)} + \alpha_{z_2}^{(2)} + \alpha_{z_1 z_2}^{(12)} + \varepsilon,$$

где $\alpha_{z_1}^{(1)}$ — эффект фактора A , $\alpha_{z_2}^{(2)}$ — эффект фактора B , $\alpha_{z_1 z_2}^{(12)}$ — эффект взаимодействия $A \times B$.

2. Аддитивная модель:

$$Y = \mu + \alpha_{z_1}^{(1)} + \alpha_{z_2}^{(2)} + \varepsilon.$$

3. Модель только с фактором B :

$$Y = \mu + \alpha_{z_2}^{(2)} + \varepsilon.$$

4. Модель только с фактором A :

$$Y = \mu + \alpha_{z_1}^{(1)} + \varepsilon.$$

5. Нулевая модель:

$$Y = \mu + \varepsilon.$$

Для проверки используем F -тест (критерий Фишера) для сравнения моделей. Статистика теста:

$$F = \frac{(SSE_{\text{restricted}} - SSE_{\text{full}})/q}{SSE_{\text{full}}/(n - p)},$$

где:

- SSE — сумма квадратов ошибок $SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$;
- q — разница в числе параметров в моделях ($q = p_{\text{full}} - p_{\text{restricted}}$);
- n — число наблюдений;
- p — число параметров в полной модели.

Таблица с данными дисперсионного анализа:

H	SSE	Df_{diff}	$MRSS$	F	$F_{\text{крит}}$
$H_{(12)}$	9030.636	3	3010.212	780.981	2.839
$H_{(1)}$	9171.095	4	2292.774	594.846	2.606
$H_{(2)}$	13987.596	6	2331.266	604.833	2.336
$H_{(0)}$	14128.056	7	2018.294	523.634	2.249
Err	154.176	40	3.854	—	—

Таблица 13. Результаты анализа

Описание столбцов таблицы

- Столбец « H » — проверяемая гипотеза.
- Столбец « SSE » — Sum Squared Errors (сумма квадратов остатков) — мера необъясненной дисперсии модели, то есть насколько модель ошибается в предсказаниях:

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2,$$

где Y_i — реальное значение, $\hat{Y}_i$ — предсказанное моделью. Чем меньше SSE , тем лучше модель объясняет данные.

- Столбец « Df_{diff} » (число степеней свободы) — количество «независимых» частей информации, использованных для оценки модели:

$$Df = n - p,$$

где n — число уникальных комбинаций уровней факторов, p — число параметров модели. Разница между числом параметров в редуцированной и полной моделях.

Всего уникальных комбинаций $A \times B = 8$, где у фактора A 2 уровня, у B — 4.

Для строки Err это значение: $Df = n - p$, где n — число наблюдений, p — число параметров в модели.

- Столбец « $MRESS$ » — Mean Residual Sum of Squares (средний квадрат ошибки) — оценка дисперсии ошибки модели:

$$MRESS = \frac{SSE}{Df_{\text{diff}}}.$$

- Столбец « F » — F -статистика — показатель значимости дополнительных факторов при переходе от редуцированной к полной модели.
- Столбец « $F_{\text{крит}}$ » — критическое значение F -распределения — пороговое значение F -статистики при заданном уровне значимости $\alpha = 0.05$.

Если $F_{\text{набл}} > F_{\text{крит}}$, то нулевая гипотеза отвергается. Если $F_{\text{набл}} \leq F_{\text{крит}}$, то нет оснований отвергать нулевую гипотезу.

Интерпретация результатов

- $H_{(12)}$ $F_{\text{набл}} = 780.981 > F_{\text{крит}} = 2.839$.
Нулевая гипотеза отвергается $\Rightarrow$ взаимодействие $A \times B$ значимо.
- $H_{(1)}$: $F_{\text{набл}} = 594.846 > F_{\text{крит}} = 2.606$.
Нулевая гипотеза отвергается $\Rightarrow$ фактор A значим.
- $H_{(2)}$: $F_{\text{набл}} = 604.833 > F_{\text{крит}} = 2.336$.
Нулевая гипотеза отвергается $\Rightarrow$ фактор B значим.
- $H_{(0)}$: $F_{\text{набл}} = 523.634 > F_{\text{крит}} = 2.249$.
Нулевая гипотеза отвергается $\Rightarrow$ все факторы (A , B , $A \times B$) значимы.

Таким образом, поскольку для всех факторов выполняется условие $F_{\text{набл}} > F_{\text{крит}}$, факторы (A), (B) и их взаимодействие ($A \times B$) оказывают статистически значимое влияние на зависимую переменную (Y).

е)

Задача: выбрать наилучшую модель с использованием AIC и BIC.

AIC (Информационный критерий Акаике) основан на минимизации информационной энтропии:

$$AIC = 2k - 2 \ln(\hat{L}),$$

где k — число параметров, $\hat{L}$ — максимизированное значение функции правдоподобия.

Чем меньше $\ln(L)$, тем лучше модель объясняет данные. В то же время штраф $2k$ увеличивается с ростом количества параметров k .

BIC (Байесовский информационный критерий) аппроксимирует логарифм апостериорной вероятности:

$$\text{BIC} = k \ln(n) - 2 \ln(L).$$

У BIC более строгий штраф за большое количество параметров: $k \ln(n)$. Чем меньше значения AIC/BIC, тем лучше модель. Различия > 2 считаются значимыми.

Для сравнения моделей рассчитаны значения AIC и BIC для следующих моделей:

- Полная модель ($A \times B$): $Y = \mu + \alpha_{z_1}^{(1)} + \alpha_{z_2}^{(2)} + \alpha_{z_1 z_2}^{(12)} + \varepsilon$;
- Аддитивная модель ($A + B$): $Y = \mu + \alpha_{z_1}^{(1)} + \alpha_{z_2}^{(2)} + \varepsilon$;
- Модель только с фактором A : $Y = \mu + \alpha_{z_1}^{(1)} + \varepsilon$;
- Модель только с фактором B : $Y = \mu + \alpha_{z_2}^{(2)} + \varepsilon$;
- Нулевая модель (только константа): $Y = \mu + \varepsilon$.

Модель	AIC	BIC
Полная ($A \times B$)	210.2290	227.0698
Аддитивная ($A + B$)	400.4152	411.6424
A	415.1311	420.7447
B	399.1436	408.4997
Нулевая (константа)	413.6055	417.3479

Таблица 14. Сравнение моделей по AIC и BIC

Полная модель ($A \times B$) имеет наименьшие AIC и BIC, следовательно, она является наилучшей. Это означает, что взаимодействие между факторами A и B значимо для объяснения данных. Все остальные модели значительно хуже по информационным критериям, чем полная.

f)

В ходе двухфакторного дисперсионного анализа зависимости переменной Y от факторов A (2 уровня) и B (4 уровня) по выборке объема $n = 48$ были получены следующие результаты.

Оценка параметров полной модели. Модель с взаимодействием:

$$E(Y \mid A = a_i, B = b_j) = \mu + \alpha_i^{(1)} + \alpha_j^{(2)} + \alpha_{ij}^{(12)}.$$

МНК-оценки (базовые уровни: A_1, B_1):

$$\hat{\mu} = 60.94, \quad \hat{\alpha}_2^{(1)} = -30.38, \quad \hat{\alpha}_2^{(2)} = -31.35, \quad \hat{\alpha}_3^{(2)} = -23.35, \quad \hat{\alpha}_4^{(2)} = 8.12.$$

Эффекты взаимодействия: $\hat{\alpha}_{22}^{(12)} = 34.57, \hat{\alpha}_{23}^{(12)} = 68.55, \hat{\alpha}_{24}^{(12)} = 4.70$. Несмещённая оценка дисперсии ошибки: $\hat{\sigma}^2 = \text{SSE}/(n - r) = 154.18/40 = 3.854$.

Проверка аддитивности (визуальная). График зависимости Y от уровня фактора A при каждом фиксированном значении B показывает, что линии для разных уровней B непараллельны и пересекаются: для B_1 и B_4 значения Y убывают при переходе $A_1 \rightarrow A_2$, тогда как для B_2 и B_3 — возрастают. Наблюдается эффект пересечения факторов, данные не согласуются с предположением аддитивности.

Анализ остатков. Гистограмма остатков полной модели имеет форму, близкую к колоколообразной, что визуально согласуется с гипотезой нормальности $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Дисперсионный анализ (F-тест).

Гипотеза	SSE	df	MRSS	$F_{\text{набл}}$	$F_{\text{крит}} (\alpha=0.05)$
$H_{(12)}$: нет взаимодействия $A \times B$	9030.64	3	3010.21	780.98	2.84
$H_{(1)}$: нет влияния A	9171.10	4	2292.77	594.85	2.61
$H_{(2)}$: нет влияния B	13987.60	6	2331.27	604.83	2.34
$H_{(0)}$: нет влияния факторов	14128.06	7	2018.29	523.63	2.25
Err (остаток полной модели)	154.18	40	3.85	—	—

Строка **Err** соответствует полной модели и содержит остаточную сумму квадратов ($\text{SSE} = 154.18, df = 40$), которая служит знаменателем F -статистики для всех гипотез.

Для всех гипотез $F_{\text{набл}} \gg F_{\text{крит}}$, то есть все они отвергаются: взаимодействие $A \times B$, главный эффект A и главный эффект B — все значимы на уровне $\alpha = 0.05$.

Выбор модели по AIC и BIC.

Модель	AIC	BIC
Полная ($A \times B$)	210.23	227.07
Аддитивная ($A + B$)	400.42	411.64
Только A	415.13	420.74
Только B	399.14	408.50
Нулевая (константа)	413.61	417.35

Полная модель с взаимодействием имеет наименьшие AIC и BIC. Разрыв с ближайшей конкурирующей моделью составляет $\Delta\text{AIC} > 190$, что является подавляющим свидетельством в пользу полной модели.

Оба фактора — A и B — а также их взаимодействие $A \times B$ оказывают статистически значимое влияние на переменную Y . Наилучшей по совокупности всех критериев (F-тест, AIC, BIC) является полная модель с взаимодействием:

$$Y_{ijk} = \mu + \alpha_i^{(1)} + \alpha_j^{(2)} + \alpha_{ij}^{(12)} + \varepsilon_{ijk}, \quad \varepsilon_{ijk} \sim \mathcal{N}(0, \sigma^2).$$

Гистограмма остатков с шагом $h = 0.69$ для первой части




Рис. 11. Гистограмма остатков с заданным шагом

Гистограмма остатков с шагом $h = 1.70$ для второй части




Рис. 12. Гистограмма остатков с заданным шагом